

Sumário Executivo

Contexto

A **BF LUBS** é uma empresa fictícia especializada na **produção e distribuição de lubrificantes industriais**, com atuação em múltiplas regiões do Brasil e atendimento a setores como Energia e Químicos, Ciência e Saúde e Manufatura. Entre 2018 e 2024, a empresa registrou uma **queda expressiva no volume de vendas**, levantando preocupações estratégicas sobre sua competitividade e sustentabilidade no mercado.

O que foi feito

Foi conduzida uma **Análise Descritiva e Exploratória de Dados (EDA)** sobre o histórico de vendas da empresa, cobrindo as seguintes etapas:

- Carregamento e inspeção dos dados** — verificação da estrutura, tipos de variáveis e qualidade dos dados.
- Análise de tendências temporais** — evolução do volume, receita, preço médio e número de clientes ativos ao longo do tempo.
- Segmentação por produto, mercado, região e estado** — identificação de onde e em quais categorias a queda é mais intensa.
- Segmentação de clientes por faixa de volume** — classificação dos clientes em perfis de consumo (Baixo, Médio, Alto e Muito Alto) para entender quais perfis concentram a perda.
- Tratamento de outliers** — aplicação do método IQR e uso de conhecimento de domínio para definir limites realistas.
- Comparação 2018 vs. 2024** — análise da variação de volume médio mensal por região, mercado e faixa de cliente.
- Análise de Pareto** — identificação dos segmentos que mais contribuíram para a queda acumulada de volume.

Principais Achados

Achado	Detalhe
Queda de volume concentrada no Lubs1	O produto Lubs1 é o principal responsável pelo declínio, sendo o de maior volume histórico
Receita resistente apesar da queda de volume	O aumento do preço médio sustentou a receita, mascarando a erosão de base de clientes
Perda crítica na faixa "Muito Alto"	Clientes com volume acima de 900 L/mês reduziram tanto volume quanto quantidade
Queda distribuída geograficamente	Nenhuma região ou estado isolado explica a queda, embora as regiões Sul e Sudeste apresentem maiores bases de venda; o problema é sistêmico
Mercados-chave: Energia/Químicos, Ciência/Saúde e Manufatura	Esses segmentos representam o maior volume e, portanto, o maior risco de perda
Pareto revela focos prioritários	Poucos segmentos concentram a maior parte da queda acumulada

Conclusão

A BF LUBS enfrenta um problema estrutural de perda de clientes de alto valor. A queda de volume não é pontual ou sazonal — é uma tendência de longo prazo que impacta de forma transversal regiões, estados e mercados. A prioridade estratégica deve ser a **retenção e recuperação dos clientes de faixa "Muito Alto"**, com foco especial nos segmentos identificados na análise de Pareto.

Contexto: A Situação da BF LUBS

A **BF LUBS**, uma empresa especializada na produção e distribuição de lubrificantes industriais, tem enfrentado uma **queda constante no volume de vendas nos últimos anos**. Apesar de ser reconhecida pela qualidade de seus produtos, a empresa observou uma redução significativa no número de clientes ativos e na quantidade de pedidos realizados.

Essa queda tem impactado diretamente a **participação de mercado** da BF LUBS, colocando em risco sua posição de destaque no setor. Curiosamente, mesmo com o declínio no volume de vendas, a **receita total** apresentou leve aumento, indicando possíveis alterações no mix de produtos ou mudanças no comportamento dos clientes.

Objetivo da análise

Através da análise exploratória, entender as questões associadas a queda de volume da organização, descrevendo cada etapa e resultado para o fácil entendimento do leitor e, ao fim, sugerir os próximos passos a serem tomados pela empresa BF LUBS.

Perguntas do negócio

- Quais produtos são os maiores responsáveis pela queda?*
- A queda de volume está impactando a receita da empresa?*
- Quais perfis de clientes (por volume de compra) estão sendo mais perdidos?*

4. A queda está concentrada em algum mercado específico ou é generalizada?
5. A empresa está perdendo clientes, ou os clientes existentes estão comprando menos — ou ambos?
6. Quais ações a empresa deve tomar para recuperar seu volume de vendas?

1. Configuração do Ambiente e carregamento dos dados

Antes de iniciar qualquer análise, é necessário preparar o ambiente de trabalho. Nesta etapa, importamos as bibliotecas utilizadas, carregamos os dados e configuramos eles. Essa etapa é fundamental para entender a estrutura do dataset: Quais colunas estão disponíveis, quais são os tipos de dados e se há valores ausentes ou inconsistências que precisam ser tratadas antes da análise.

Bibliotecas utilizadas:

- **pandas** — manipulação e análise de dados tabulares
- **matplotlib / seaborn** — criação de visualizações gráficas
- **warnings** — supressão de alertas desnecessários durante a execução

```
In [1]: #Bibliotecas
import pandas as pd
import seaborn as sns
import warnings
import matplotlib.pyplot as plt

# Libraries

import pandas as pd
import seaborn as sns
import warnings
import matplotlib.pyplot as plt

# Columns and rows

pd.set_option("display.max_columns", None)
pd.set_option("display.max_rows", None)
pd.options.display.float_format = '{:,.2f}'.format
```

```
In [2]: #Importando os dados
#Verificando colunas
df= pd.read_csv('BF LUBS Sales.csv')
df.sample(10)
```

Out[2]:

	Ano e Mês	ID Cliente	Nome Cliente	Produto	UoM	Volume	Receita	Preço	Mercado	Regiao	Latitude_Regional	Longitude_Regional
520852	2021-12	BF-CL1003116	Cliente_3117	LUB-BF-SPEC-01	LT	292	849	2.91	Governo	Sul	-25.43	-51.92
31466	2021-04	BF-CL1000004	Cliente_5	LUB-BF-SPEC-01	LT	292	165	0.57	Ciências e Saúde	Centro Oeste	-15.78	-47.92
3264	2021-04	BF-CL1002003	Cliente_2004	LUB-BF-SPEC-01	LT	292	495	1.70	Ciências e Saúde	Nordeste	-8.05	-34.88
388629	2022-12	BF-CL1015239	Cliente_15240	LUB-BF-SPEC-01	LT	292	319	1.09	Ciências e Saúde	Sudeste	-23.55	-46.63
592298	2023-06	BF-CL1000536	Cliente_537	LUB-BF-SPEC-01	LT	292	0	0.00	Energia e Químicos	Nordeste	-8.05	-34.88
364594	2023-07	BF-CL1000343	Cliente_344	LUB-BF-SPEC-01	LT	244	360	1.48	Energia e Químicos	Sudeste	-23.55	-46.63
159701	2022-02	BF-CL1003702	Cliente_3703	LUB-BF-SPEC-01	LT	584	229	0.39	Manufatura	Sudeste	-23.55	-46.63
481959	2019-01	BF-CL1008767	Cliente_8768	LUB-BF-SPEC-01	LT	292	136	0.47	Ciências e Saúde	Nordeste	-8.05	-34.88
376878	2020-11	BF-CL1000059	Cliente_60	LUB-BF-SPEC-01	LT	584	455	0.78	Energia e Químicos	Sudeste	-23.55	-46.63
238196	2018-04	BF-CL1000375	Cliente_376	LUB-BF-SPEC-01	LT	584	303	0.52	Ciências e Saúde	Sul	-25.43	-51.92

```
In [3]: df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 601836 entries, 0 to 601835
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Ano e Mês              601836 non-null  str
1   ID Cliente             601836 non-null  str
2   Nome Cliente           601836 non-null  str
3   Produto                601836 non-null  str
4   UoM                    601836 non-null  str
5   Volume                 601836 non-null  int64
6   Receita                601836 non-null  int64
7   Preço                  601836 non-null  float64
8   Mercado                596037 non-null  str
9   Regiao                 601836 non-null  str
10  Latitude_Regional      601836 non-null  float64
11  Longitude_Regional     601836 non-null  float64
12  Estado                 601836 non-null  str
13  Filial                 601836 non-null  str
14  Latitude_Filial        601836 non-null  float64
15  Longitude_Filial       601836 non-null  float64
16  Latitude_Cliente       601836 non-null  float64
17  Longitude_Cliente      601836 non-null  float64
dtypes: float64(7), int64(2), str(9)
memory usage: 82.6 MB
```

```
In [4]: df['Ano e Mês'] = pd.to_datetime(df['Ano e Mês'], format= '%Y-%m') #Transformando o ano e mês para datetime
df.sample(5)
```

Out[4]:


	Ano e Mês	ID Cliente	Nome Cliente	Produto	UoM	Volume	Receita	Preço	Mercado	Regiao	Latitude_Regional	Longitude_Regional
583212	2018-09-01	BF-CL1000358	Cliente_359	LUB-BF-SPEC-01	LT	584	204	0.35	Ciências e Saúde	Sul	-25.43	-49.2
436960	2019-08-01	BF-CL1001057	Cliente_1058	LUB-BF-SPEC-01	LT	134	134	1.00	Energia e Químicos	Sudeste	-23.55	-46.6
577294	2020-02-01	BF-CL1001961	Cliente_1962	LUB-BF-SPEC-01	LT	1752	906	0.52	Energia e Químicos	Sudeste	-23.55	-46.6
283832	2020-06-01	BF-CL1000833	Cliente_834	LUB-BF-SPEC-01	LT	584	0	0.00	Outros Canais de Venda	Sul	-25.43	-49.2
508497	2020-05-01	BF-CL1000571	Cliente_572	LUB-BF-SPEC-01	LT	292	101	0.35	Ciências e Saúde	Centro Oeste	-15.78	-47.9

2. Análise de Tendências Temporais

Com os dados carregados, analisamos as **principais métricas de negócio ao longo do tempo**: volume vendido, receita gerada, número de clientes ativos e preço médio. Esses gráficos fornecem a visão macro da evolução da empresa e são o ponto de partida para identificar onde e quando a situação começou a se deteriorar.

```
In [5]: #Volume
Volume_por_mes = df.groupby('Ano e Mês')['Volume'].sum() #
Volume_por_mes.plot(kind= 'line',title='Volume por ano e mês',figsize=(12,6))
#Queda de 2018 até 2020, após queda grande em 2022, dados se estabilizam.
```

```
Out[5]: <Axes: title={'center': 'Volume por ano e mês'}, xlabel='Ano e Mês'>
```




Interpretação — Volume por Ano e Mês

O gráfico revela uma **tendência de queda contínua no volume total vendido** entre 2018 e 2024. A queda é mais proeminente entre 2018 e 2020, com um segundo colapso expressivo por volta de 2022. Após esse ponto, o volume se estabiliza em patamar significativamente inferior ao inicial.

```
In [6]: #Receita
Receita_por_mes = df.groupby('Ano e Mês')['Receita'].sum() #
Receita_por_mes.plot(kind= 'line',title='Receita por ano e mês',figsize=(12,6))
```

Out[6]: <Axes: title={'center': 'Receita por ano e mês'}, xlabel='Ano e Mês'>



Interpretação — Receita por Ano e Mês

Diferentemente do volume, a **Receita apresenta um crescimento sustentado**, esse crescimento indica que de alguma maneira a empresa tem compensado a perda de volume, seja através de uma operação mais eficiente, aumento de preços ou mudança no mix de produtos.

```
In [ ]: #Clientes
Clientes_por_mes = df.groupby('Ano e Mês')['ID Cliente'].nunique() #
Clientes_por_mes.plot(kind= 'line',title='Clientes por ano e mês',figsize=(12,6))
df.columns
```


```
Out[ ]: Index(['Ano e Mês', 'ID Cliente', 'Nome Cliente', 'Produto', 'UoM', 'Volume',
            'Receita', 'Preço', 'Mercado', 'Regiao', 'Latitude_Regional',
            'Longitude_Regional', 'Estado', 'Filial', 'Latitude_Filial',
            'Longitude_Filial', 'Latitude_Cliente', 'Longitude_Cliente'],
            dtype='str')
```

Interpretação — Clientes por Ano e Mês

O número de clientes ativos mensais também apresenta **queda consistente ao longo do período**. A perda de clientes acompanha, e provavelmente explica em grande parte, a queda no volume. Vale destacar que não se trata de uma oscilação sazonal: a tendência é unidirecional e persistente, configurando um problema estrutural de retenção de clientes.

```
In [ ]: #Preço
Preco_por_mes = df.groupby('Ano e Mês')['Preço'].mean() #
Preco_por_mes.plot(kind= 'line',title='Preço por ano e mês',figsize=(12,6))
```

```
Out[ ]: <Axes: title={'center': 'Preço por ano e mês'}, xlabel='Ano e Mês'>
```



Interpretação — Preço Médio por Ano e Mês


O preço médio praticado pela BF LUBS apresenta **trajetória de alta ao longo do período**. Esse aumento é consistente com a hipótese levantada no gráfico de receita: a empresa vem reajustando seus preços, o que sustenta o faturamento, mas pode estar **acelerando a perda de clientes mais sensíveis ao preço**, especialmente os de maior volume, que têm maior poder de negociação ou encontram alternativas mais competitivas no mercado. A grande queda no volume de vendas em 2022 pode ser explicada pela grande alta dos preços no mesmo momento, no gráfico de Preço médio.

4. Análise por Produto

Compreendida a tendência geral, segmentamos os dados por **produto** para identificar quais itens do portfólio contribuem mais para o volume total e quais são os mais impactados pela queda.

```
In [ ]: #Volume por Ano e Mês
produto_por_mes = df.groupby(['Ano e Mês', 'Produto'])['Volume'].sum().unstack()
produto_por_mes.plot(kind= 'area', title='Volume por Ano e Mês', figsize=(12,6))
```

```
Out[ ]: <Axes: title={'center': 'Volume por Ano e Mês'}, xlabel='Ano e Mês'>
```




Interpretação — Volume por Produto ao Longo do Tempo

O gráfico de área empilhada evidencia que o **Lubs1 domina o volume** em todos os períodos analisados e que sua redução é a principal responsável pela contração geral. Os demais produtos (Lubs2, Lubs3 etc.) apresentam volumes menores e relativamente mais estáveis, indicando que o problema está concentrado no principal produto da linha.

```
In [ ]: #Volume por produto
produto = df.groupby('Produto')['Volume'].sum()
produto.plot(kind= 'bar', title='Volume por produto', rot=0,figsize=(12,6))

Out[ ]: <Axes: title={'center': 'Volume por produto'}, xlabel='Produto'>
```



Interpretação — Volume Total por Produto

O gráfico de barras confirma que o **Lubs1 responde pela maior parte do volume acumulado**, com folga significativa sobre os demais produtos. Essa concentração é um risco estratégico: qualquer deterioração no desempenho do Lubs1 tem impacto desproporcional sobre os resultados globais da empresa — exatamente o que os dados revelam estar acontecendo.

Insight: A diversificação do portfólio ou ações específicas de retenção de clientes do Lubs1 devem ser prioridade estratégica.


5. Análise por Mercado

Com o produto-chave identificado, expandimos a análise para entender o comportamento por **segmento de mercado**, verificando quais setores industriais concentram maior volume e como evoluíram ao longo do tempo.

```
In [ ]: #UoM
#df['UoM'].unique()
```

```
In [ ]: #Volume por Mercado
Mercado = df.groupby(['Ano e Mês', 'Mercado'])['Volume'].sum().unstack()
Mercado.plot(kind= 'area', title='Volume por ano e mês #mercado',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Volume por ano e mês #mercado'}, xlabel='Ano e Mês'>




Interpretação — Volume por Mercado ao Longo do Tempo

O gráfico de área por mercado mostra que a queda de volume é generalizada entre os segmentos, sem que um único setor isolado seja responsável pelo declínio. Por serem os maiores em volume, os mercados de **Energia e Químicos** e **Ciência e Saúde** contribuem mais para a queda absoluta.

```
In [ ]: Mercado = df.groupby('Mercado')['Volume'].sum()
Mercado.plot(kind= 'bar', title='Volume por mercado',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Volume por mercado'}, xlabel='Mercado'>



Interpretação — Volume Total por Mercado


Os três mercados que mais consomem produto da BF LUBS são **Energia e Químicos**, **Ciência e Saúde** e **Manufatura**. Juntos, representam a maior parte do volume total, tornando-se os segmentos prioritários tanto para ações de retenção quanto para investigações sobre por que a demanda vem caindo nessas verticais.

6. Análise Geográfica

Com o panorama de produto e mercado estabelecido, investigamos se a queda possui algum **padrão geográfico** — se determinadas regiões ou estados apresentam queda mais acentuada ou se o problema está distribuído de forma homogênea pelo território.

```
In [ ]: #Região por Ano e Mês
regiao_por_mes = df.groupby(['Ano e Mês', 'Regiao'])['Volume'].sum().unstack()
regiao_por_mes.plot(kind= 'area', title='Região por Ano e Mês #Região',figsize=(12,6))

Out[ ]: <Axes: title={'center': 'Região por Ano e Mês #Região'}, xlabel='Ano e Mês'>
```





Interpretação — Volume por Região ao Longo do Tempo

O gráfico de área por região mostra que **todas as regiões seguem a mesma tendência de queda**, sem que haja uma região cujo colapso se destaque significativamente sobre as demais. Isso reforça a hipótese de que o problema é sistêmico, e não localizado.

```
In [ ]: #Região
regiao = df.groupby('Regiao')['Volume'].sum()
regiao.plot(kind= 'bar', title='Volume por Região',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Volume por Região'}, xlabel='Regiao'>




Interpretação — Volume Total por Região

As regiões **Sul e Sudeste** concentram o maior volume acumulado, o que é esperado pela maior densidade industrial. A ausência de discrepância regional na queda indica que **não há fator logístico ou geográfico** como causa primária da deterioração.

```
In [ ]: estado_por_mes = df.groupby(['Ano e Mês', 'Estado'])['Volume'].sum().unstack()
estado_por_mes.plot(kind='area', title='Volume por Ano e Mês #Região', figsize=(13,7))
```

```
plt.legend(loc='upper left', bbox_to_anchor=(1, 1), title='Estado')
plt.tight_layout()
```




Interpretação — Volume por Estado ao Longo do Tempo

Descendo até o nível de estado, a conclusão se mantém: **não há um estado específico com queda dramaticamente superior** aos demais. A queda é uniforme, o que descarta causas locais como mudanças regulatórias estaduais ou perda de um grande cliente regional isolado.

```
In [ ]: estado = df.groupby('Estado')['Volume'].sum()
estado.plot(kind='bar', title='Volume por Estado',figsize=(12,6))
```

```
Out[ ]: <Axes: title={'center': 'Volume por Estado'}, xlabel='Estado'>
```



Interpretação — Volume Total por Estado

Em volume acumulado, estados do **Sul e Sudeste** lideram, alinhados com a análise regional. A distribuição entre estados é relativamente equilibrada, sem outliers que indiquem problema pontual em um único estado.

☒ **Conclusão da análise geográfica:** A queda de volume é homogênea entre regiões e estados. O problema não é geográfico.

7. Segmentação de Clientes por Faixa de Volume

Uma vez descartadas causas geográficas, aprofundamos a análise no **perfil dos clientes**. Classificamos cada cliente por sua média mensal de volume comprado ao longo de todo o histórico, criando faixas que nos permitem entender quais perfis estão sendo perdidos e em que intensidade.


Faixa	Volume Médio Mensal
Baixo	Até 300 L
Médio	300 – 500 L
Alto	500 – 900 L
Muito Alto	Acima de 900 L

```
In [ ]: #Filial por Ano e Mês
#filial_por_mes = df.groupby(['Ano e Mês', 'Filial'])['Volume'].sum().unstack()
#filial_por_mes.plot(kind= 'area', title='Volume por Ano e Mês #Filial')
```

```
In [ ]: ##filial = df.groupby('Filial')['Volume'].sum()
##filial.plot(kind= 'bar', title='Filial por mercado')
```


```
In [ ]: #Volume por Ano e Mês
produto_por_mes = df.groupby(['Ano e Mês', 'Produto'])['Volume'].sum().unstack()
produto_por_mes.plot(kind= 'area', title='Volume por Ano e Mês',figsize=(12,6))
```

```
Out[ ]: <Axes: title={'center': 'Volume por Ano e Mês'}, xlabel='Ano e Mês'>
```



```
In [ ]: Mercado = df.groupby('Mercado')['Volume'].sum()
Mercado.plot(kind= 'bar', title='Volume por mercado',figsize=(12,6))
```

```
Out[ ]: <Axes: title={'center': 'Volume por mercado'}, xlabel='Mercado'>
```



```
In [ ]: #Adicionando uma categoria pelo volume mendio mensal de clientes
volume_mensal_clientes = df.groupby(['Ano e Mês', 'ID Cliente'])['Volume'].sum().reset_index()
volume_mensal_clientes = volume_mensal_clientes.groupby('ID Cliente')['Volume'].mean().reset_index()
```

```
In [ ]: #Analisando a distribuição dos meus dados
volume_mensal_clientes['Volume'].describe()
```

```
Out[ ]: count    16,797.00
mean      1,432.92
std       8,308.42
min        10.00
25%       292.00
50%       474.50
75%       876.00
max      495,260.00
Name: Volume, dtype: float64
```

```
In [ ]: #Criando etiquetas/faixas de clientes por volume mensal

"""
0 - 300    - Baixo
300 - 500  - Médio
500 - 900  - Alto
900+      - Muito - Alto
"""

bins = [0, 300, 500, 900, float('inf')]
labels = ['Baixo', 'Médio', 'Alto', "Muito alto" ]
```

```
In [ ]: #Adicionando a coluna da faixa para cada cliente
volume_mensal_clientes['Faixa de Volume'] = pd.cut(volume_mensal_clientes['Volume'], bins = bins, labels=labels )
volume_mensal_clientes = volume_mensal_clientes.drop(columns = ['Volume'])
volume_mensal_clientes.head()
```

```
Out[ ]:
```

	ID Cliente	Faixa de Volume
0	BF-CL1000000	Muito alto
1	BF-CL1000001	Muito alto
2	BF-CL1000002	Muito alto
3	BF-CL1000003	Muito alto
4	BF-CL1000004	Médio

```
In [ ]: #Adicionando a faixa de volume do cliente no dataframe
df = pd.merge(
    df,
    volume_mensal_clientes,
    on = 'ID Cliente',
    how= 'left'
)
df.head()
```

Out[]:

	Ano e Mês	ID Cliente	Nome Cliente	Produto	UoM	Volume	Receita	Preço	Mercado	Regiao	Latitude_Regional	Longitude_Regional	Estado
0	2023-10-01	BF-CL1000000	Cliente_1	LUB-BF-SPEC-01	LT	584	0	0.00	Outros Canais de Venda	Nordeste	-8.05	-34.88	Bahia
1	2024-09-01	BF-CL1000001	Cliente_2	LUB-BF-SPEC-01	LT	3072	6895	2.25	Governo	Nordeste	-8.05	-34.88	Alagoas
2	2022-12-01	BF-CL1000002	Cliente_3	LUB-BF-SPEC-01	LT	488	296	0.61	Governo	Nordeste	-8.05	-34.88	Paraná
3	2020-04-01	BF-CL1000003	Cliente_4	LUB-BF-SPEC-01	LT	1168	1430	1.22	Ciências e Saúde	Sudeste	-23.55	-46.63	Minas Gerais
4	2021-12-01	BF-CL1000004	Cliente_5	LUB-BF-SPEC-01	LT	292	172	0.59	Ciências e Saúde	Centro Oeste	-15.78	-47.93	Mat Grosso


```
In [ ]: #faixa por volume do cliente
faixa_volume_cliente = df.groupby(['Ano e Mês', 'Faixa de Volume'])['Volume'].sum().unstack()
faixa_volume_cliente.head(10)
```

Out[]:

Faixa de Volume	Baixo	Médio	Alto	Muito alto
Ano e Mês				
2018-01-01	75998	305113	721460	9333141
2018-02-01	72616	318915	653806	9076037
2018-03-01	84800	354770	782828	10257680
2018-04-01	74066	290180	643823	8178405
2018-05-01	78795	333969	745819	10312943
2018-06-01	77117	343252	753273	10266977
2018-07-01	69923	286595	676054	8358199
2018-08-01	73379	330626	735204	9607833
2018-09-01	67327	327610	688395	9094392
2018-10-01	70700	306469	691945	9195346

```
In [ ]: #Gráfico de Volume por faixa de clientes
faixa_volume_cliente.plot(kind='area', title='Volume por faixa de clientes',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Volume por faixa de clientes'}, xlabel='Ano e Mês'>




Interpretação — Volume por Faixa de Clientes ao Longo do Tempo

O gráfico revela de forma inequívoca onde está o maior problema: a faixa "**Muito Alto**" (clientes com compra média acima de 900 L/mês) sofreu a **maior contração de volume ao longo do período**. Enquanto as faixas inferiores apresentam queda mais suave ou relativa estabilidade, os grandes compradores reduziram drasticamente o volume adquirido, e são justamente eles que mais impactam o resultado total da empresa.

```
In [ ]: Clientes_por_mesfaixa = df.groupby(['Ano e Mês', 'Faixa de Volume'])['ID Cliente'].unique().unstack()
        Clientes_por_mesfaixa.plot(kind='area', title='Clientes por Ano e Mês por faixa',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Clientes por Ano e Mês por faixa'}, xlabel='Ano e Mês'>



Interpretação — Número de Clientes por Faixa ao Longo do Tempo

Este gráfico complementa o anterior e agrava o diagnóstico: a faixa "Muito Alto" não apenas **comprou menos por cliente**, como também **perdeu clientes em número absoluto** de forma mais intensa que as demais faixas. Estamos diante de um cenário duplo: churn (saída) de grandes clientes combinado com redução do volume dos que permaneceram.

Alerta estratégico: Perder clientes de alto volume é crítico. Cada cliente nessa faixa tem impacto equivalente a vários clientes de faixas menores. A prioridade de retenção deve estar aqui.

8. Identificação e Tratamento de Outliers

Antes de prosseguir para comparações entre períodos, é necessário garantir a **qualidade dos dados removendo registros atípicos (outliers)**. Valores extremamente altos podem distorcer médias e comparações, levando a conclusões equivocadas.

Utilizamos o método **IQR (Interquartile Range)** como ponto de partida, complementado por **conhecimento de domínio** sobre as operações logísticas da empresa.

Identificando Outliers

Usando o método do IQR (Interquartile Range) para a coluna **Volume** :

```
# Calculando o IQR
Q1 = df[coluna].quantile(0.25)
Q3 = df[coluna].quantile(0.75)
IQR = Q3 - Q1

# Definir limites superior e inferior
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR
```

```
In [ ]: df['Volume'].describe()
```

```
Out[ ]: count    601,836.00
        mean      1,079.24
        std       3,557.80
        min        2.00
        25%       292.00
        50%       584.00
        75%      1,168.00
        max      240,042.00
        Name: Volume, dtype: float64
```

```
In [ ]: Q1= df['Volume'].quantile(0.25)
        Q3= df['Volume'].quantile(0.75)
        IQR= Q3 - Q1
```

```
In [ ]: limite_inferior = Q1 - 1.5 * IQR
        limite_superior = Q3 + 1.5 * IQR

        print(f'inferior {limite_inferior} e superior {limite_superior}')

inferior -1022.0 e superior 2482.0
```

```
In [ ]: #Identificando outliers inferiores
        Outliers_inferiores = df[df['Volume']<= limite_inferior]
        Outliers_inferiores.head()
```

Out[]:

Ano e Mês	ID Cliente	Nome Cliente	Produto	UoM	Volume	Receita	Preço	Mercado	Regiao	Latitude_Regional	Longitude_Regional	Estado	Filial

```
In [ ]: #Identificando outliers superiores
        #Outliers_superiores = df[df['Volume']>= limite_superior]
        Outliers_superiores = df[df['Volume']>= 20000]
        Outliers_superiores.head()
        Outliers_superiores.info()
```



```
<class 'pandas.DataFrame'>
Index: 1051 entries, 135 to 601261
Data columns (total 19 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Ano e Mês              1051 non-null   datetime64[us]
1   ID Cliente             1051 non-null   str
2   Nome Cliente           1051 non-null   str
3   Produto                1051 non-null   str
4   UoM                    1051 non-null   str
5   Volume                 1051 non-null   int64
6   Receita                1051 non-null   int64
7   Preço                  1051 non-null   float64
8   Mercado                1027 non-null   str
9   Regiao                 1051 non-null   str
10  Latitude_Regional      1051 non-null   float64
11  Longitude_Regional     1051 non-null   float64
12  Estado                 1051 non-null   str
13  Filial                 1051 non-null   str
14  Latitude_Filial        1051 non-null   float64
15  Longitude_Filial       1051 non-null   float64
16  Latitude_Cliente       1051 non-null   float64
17  Longitude_Cliente      1051 non-null   float64
18  Faixa de Volume        1051 non-null   category
dtypes: category(1), datetime64[us](1), float64(7), int64(2), str(8)
memory usage: 157.2 KB
```

Resultado do Tratamento de Outliers

Após calcular os limites pelo método IQR:

- **Limite inferior calculado:** -1.022 L — valor negativo e impossível fisicamente; **desconsiderado**.
- **Limite superior calculado:** 2.482 L — identificou ~50.000 entradas como outliers, o que é inviável. O critério estatístico puro não foi adequado para este caso.

Recorrendo ao **conhecimento de negócio**, foi identificado que o **veículo de maior capacidade da empresa transporta 20.000 L**. Qualquer pedido acima disso seria operacionalmente impossível em uma única entrega. Aplicando esse limite de domínio, foram identificados **1.051 registros** a serem removidos — um número razoável e justificável.


```
In [ ]: # Filtro para remoção de outliers

df_wo_outliers = df[df["Volume"] <= 20000]
```

```
In [ ]: # Gráfico de volume por cliente sem outliers

faixa_volume_cliente = df_wo_outliers.groupby(['Ano e Mês', 'Faixa de Volume'])['Volume'].sum().unstack()
faixa_volume_cliente.plot(kind='area', title='Faixa de Volume por clientes',figsize=(12,6))
```

Out[]: <Axes: title={'center': 'Faixa de Volume por clientes'}, xlabel='Ano e Mês'>



Interpretação — Volume por Faixa (sem outliers)

Com a remoção dos registros atípicos, o gráfico de faixas de volume mantém **exatamente a mesma tendência** observada anteriormente. Isso confirma que os outliers não estavam distorcendo a análise — a queda é real e estrutural, especialmente na faixa "Muito Alto". A remoção foi

necessária para garantir a integridade das comparações quantitativas que seguem.

9. Comparação entre 2018 e 2024

Com a base de dados limpa, construímos uma análise comparativa focada nos **dois extremos do período**: 2018 (início) e 2024 (ano mais recente). O objetivo é quantificar exatamente **quanto volume médio mensal foi perdido** em cada combinação de Região, Mercado e Faixa de Cliente, permitindo priorizar ações de forma objetiva.

```
In [ ]: #df_wo_outliers.info()
#['Ano e Mês', 'Produto', 'Mercado', 'Regiao', 'Faixa de volume']

In [ ]: #Agrupando dados por 'Ano e Mês', 'Produto', 'Mercado', 'Regiao', 'Faixa de Volume'
volume_mensal = (
    df_wo_outliers.groupby(['Ano e Mês', 'Produto', 'Mercado', 'Regiao', 'Faixa de Volume'])['Volume']
    .sum()
    .reset_index()

)
volume_mensal['Ano'] = volume_mensal['Ano e Mês'].dt.year
volume_mensal = volume_mensal[volume_mensal['Ano'].isin([2018,2024])]
volume_mensal.head() #Dessa maneira temos uma tabela somente com as informações que precisamos.

Out[ ]:
   Ano e Mês  Produto  Mercado  Regiao  Faixa de Volume  Volume  Ano
0  2018-01-01  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Baixo    1168  2018
1  2018-01-01  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Médio    5548  2018
2  2018-01-01  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Alto    9344  2018
3  2018-01-01  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste    Muito alto  100740  2018
4  2018-01-01  LUB-BF-SPEC-01  Alimentos, Bebidas    Nordeste        Baixo    1195  2018

In [ ]: #Verificando anos distintos após do filtro
volume_mensal['Ano'].unique()

Out[ ]: array([2018, 2024], dtype=int32)

In [ ]: #Agrupando dados com a média mensal
volume_mensal_medio = (
    volume_mensal.groupby(['Ano', 'Produto', 'Mercado', 'Regiao', 'Faixa de Volume'])['Volume']
    .mean()
    .round(2) #Deixar apenas 2 casas decimais
    .rename('Volume Médio')
    .reset_index()

)
volume_mensal_medio.head()

Out[ ]:
   Ano  Produto  Mercado  Regiao  Faixa de Volume  Volume Médio
0  2018  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Baixo    1,015.50
1  2018  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Médio    4,513.92
2  2018  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste        Alto    8,468.00
3  2018  LUB-BF-SPEC-01  Alimentos, Bebidas  Centro Oeste    Muito alto  109,726.83
4  2018  LUB-BF-SPEC-01  Alimentos, Bebidas    Nordeste        Baixo    972.92

In [ ]: #Comparando os períodos
volume_sumarizado = pd.pivot_table(
    volume_mensal_medio,
    index = [ 'Regiao', 'Mercado', 'Faixa de Volume'],
    values = 'Volume Médio',
    columns = 'Ano',
    aggfunc = 'sum',
    margins = True,
    margins_name= 'Total geral'
).reset_index()

# Removendo valores maiores que 0 da tabela
volume_sumarizado = volume_sumarizado[volume_sumarizado['Total geral'] > 0]
volume_sumarizado = volume_sumarizado[volume_sumarizado['Regiao']!= 'Total geral']

# Removendo total geral da tabela
volume_sumarizado = volume_sumarizado.drop(columns=['Total geral'])

# Gerando a diferença
```

```
volume_sumarizado['Dif.'] = volume_sumarizado[2024] - volume_sumarizado[2018]
volume_sumarizado['Dif %'] = volume_sumarizado['Dif.'] / volume_sumarizado[2018] * 100

volume_sumarizado.sort_values(by='Dif.', ascending=True).reset_index(drop=True).head()
```

Out []:

	Ano	Regiao	Mercado	Faixa de Volume	2018	2024	Dif.	Dif %
0		Sudeste	Energia e Químicos	Muito alto	2,271,945.48	1,307,621.63	-964,323.85	-42.44
1		Sul	Ciências e Saúde	Muito alto	769,482.08	515,672.60	-253,809.48	-32.98
2		Centro Oeste	Manufatura	Muito alto	360,305.33	119,034.35	-241,270.98	-66.96
3		Centro Oeste	Energia e Químicos	Muito alto	425,902.33	193,188.53	-232,713.80	-54.64
4		Sul	Energia e Químicos	Muito alto	531,214.24	298,510.47	-232,703.77	-43.81

In []:

```
df_wo_outliers.head()
```

Out []:

	Ano e Mês	ID Cliente	Nome Cliente	Produto	UoM	Volume	Receita	Preço	Mercado	Regiao	Latitude_Regional	Longitude_Regional	Estado
0	2023-10-01	BF-CL1000000	Cliente_1	LUB-BF-SPEC-01	LT	584	0	0.00	Outros Canais de Venda	Nordeste	-8.05	-34.88	Bahia
1	2024-09-01	BF-CL1000001	Cliente_2	LUB-BF-SPEC-01	LT	3072	6895	2.25	Governo	Nordeste	-8.05	-34.88	Alagoas
2	2022-12-01	BF-CL1000002	Cliente_3	LUB-BF-SPEC-01	LT	488	296	0.61	Governo	Nordeste	-8.05	-34.88	Paraná
3	2020-04-01	BF-CL1000003	Cliente_4	LUB-BF-SPEC-01	LT	1168	1430	1.22	Ciências e Saúde	Sudeste	-23.55	-46.63	Minas Gerais
4	2021-12-01	BF-CL1000004	Cliente_5	LUB-BF-SPEC-01	LT	292	172	0.59	Ciências e Saúde	Centro Oeste	-15.78	-47.93	Mat Grosso


10. Visualizando os Impactos entre 2018 e 2024

Com a tabela comparativa construída, geramos visualizações da **diferença de volume médio mensal** entre 2018 e 2024, segmentadas por região e mercado. Valores negativos indicam queda — quanto maior o valor absoluto, maior a perda acumulada naquele segmento.

In []:

```
# Região


regiao_dif = volume_sumarizado.groupby('Regiao')['Dif.'].sum().sort_values(ascending=False)
regiao_dif.plot(kind='barh', figsize=(12,6))
plt.title('Diferença por região(2018 vs 2024)')
plt.show()
```



Interpretação — Diferença de Volume por Região (2018 vs 2024)

O gráfico evidencia que basicamente **todas as regiões apresentam variação negativa**, confirmando a natureza sistêmica da queda. As regiões de maior volume histórico (Sul e Sudeste) naturalmente registram as maiores perdas absolutas, mas a proporcionalidade sugere que nenhuma região está imune ao problema.


```
In [ ]: #Mercado
mercado_dif = volume_sumarizado.groupby('Mercado')['Dif.'].sum().sort_values(ascending=False)
mercado_dif.plot(kind='barh', figsize=(12,6))
plt.title('Diferença por Mercado(2018 vs 2024)')
plt.show()
```



Interpretação — Diferença de Volume por Mercado (2018 vs 2024)

A queda de volume não é uniforme entre os mercados — ela é **fortemente concentrada em três segmentos: Energia e Químicos, Ciências e Saúde e Manufatura** respondem pela esmagadora maioria da perda acumulada. Esse padrão indica que o problema da BF LUBS está **concentrado nos seus mercados mais relevantes**, a empresa está perdendo volume justamente onde mais importa. Ações de retenção e recuperação devem ser direcionadas prioritariamente a esses três segmentos.

```
In [ ]: #Faixa de Volume
mercado_dif = volume_sumarizado.groupby('Faixa de Volume')['Dif.'].sum().sort_values(ascending=False)
mercado_dif.plot(kind='barh', figsize=(12,6))
plt.title('Diferença por Mercado(2018 vs 2024)')
plt.show()
```



Interpretação — Diferença de Volume por Faixa de Cliente (2018 vs 2024)

A faixa **"Muito Alto"** concentra praticamente toda a queda acumulada de volume, com perda absolutamente desproporcional em relação às demais faixas. As faixas "Alto", "Médio" e "Baixo" apresentam variações quase irrelevantes em comparação — confirmando que o problema central da BF LUBS é a **perda de seus maiores clientes**, e não uma erosão distribuída pela base.

11. Análise de Pareto — Identificando os Maiores Offenders

A etapa final aplica o **Princípio de Pareto (80/20)** para identificar **quais combinações de Região + Mercado + Faixa de Cliente** concentram a maior parte da queda acumulada de volume. Essa visão permite à liderança da BF LUBS agir de forma cirúrgica, priorizando os segmentos com maior potencial de recuperação de volume.

```
In [ ]: #Preparando para análise de Pareto
pareto_df= volume_sumarizado
pareto_df['Regiao Mercado e Volume'] = pareto_df['Regiao'] + ' | ' + pareto_df['Mercado']+ ' | ' + pareto_df['Faixa de Volume']
pareto_df = pareto_df.sort_values(by='Dif.')#Ordenando valores
pareto_df = pareto_df[pareto_df['Dif.']<0] #Removendo Positivos
pareto_df['Dif.'] = pareto_df['Dif.'].abs()#Transformando negativo em absoluto
pareto_df= pareto_df[['Regiao', 'Mercado', 'Faixa de Volume', 'Regiao Mercado e Volume', 'Dif.']] #selecionando coluna

pareto_df['Dif % Acumulado'] = pareto_df['Dif.'].cumsum() / pareto_df['Dif.'].sum() * 100 #adicionando % acumulado

pareto_df.head()
```

Out[]:

	Ano	Regiao	Mercado	Faixa de Volume	Regiao Mercado e Volume	Dif.	Dif % Acumulado
	98	Sudeste	Energia e Químicos	Muito alto	Sudeste Energia e Químicos Muito alto	964,323.85	28.95
	127	Sul	Ciências e Saúde	Muito alto	Sul Ciências e Saúde Muito alto	253,809.48	36.57
	25	Centro Oeste	Manufatura	Muito alto	Centro Oeste Manufatura Muito alto	241,270.98	43.82
	15	Centro Oeste	Energia e Químicos	Muito alto	Centro Oeste Energia e Químicos Muito alto	232,713.80	50.81
	135	Sul	Energia e Químicos	Muito alto	Sul Energia e Químicos Muito alto	232,703.77	57.79

```
In [ ]: #Selecionando top 15 dif.

pareto_top15 = pareto_df.nlargest(15, 'Dif.')


#Gráfico de Pareto

#Eixo principal
ax = pareto_top15.plot(kind='bar', x= 'Regiao Mercado e Volume', y='Dif.', legend=False, figsize=(12,6))

#Eixo secundário para visualização da porcentagem acumulada
ax2 = ax.twinx()
ax2.plot(
    pareto_top15['Regiao Mercado e Volume'],
    pareto_top15['Dif % Acumulado'],
    color = 'red', marker= 'o', linestyle = '- ', linewidth=1,
)

#Formatando o gráfico
ax2.set_ylim(0,100)#Limite do eixo secundário
ax.tick_params(axis='x', rotation=45, labels=6)#ajustando rótulos
ax.set_title('Gráfico de pareto - Top 15 Offenders') #Título

plt.tight_layout()
plt.show()
```



Interpretação — Gráfico de Pareto (Top 15 Segmentos)

O gráfico de Pareto combina **barras** (queda absoluta de volume por segmento) com uma **linha de porcentagem acumulada** (eixo direito). Os primeiros segmentos à esquerda são os maiores responsáveis pela queda total.

A linha cruza rapidamente o limiar de 80%, confirmando que **um número pequeno de combinações de Região + Mercado + Faixa de Volume** concentra a maior parte da perda. Esses são os segmentos que exigem atenção imediata; sejam alvos de programas de fidelização, renegociação de condições comerciais ou investigação de causa raiz junto aos próprios clientes.

Principais Achados

A análise exploratória dos dados de vendas da BF LUBS entre 2018 e 2024 revelou um cenário de **deterioração estrutural e consistente** em toda a operação comercial da empresa:

- O **volume total vendido caiu de forma contínua** ao longo de todo o período, com quedas mais abruptas entre 2018–2020 e novamente em 2022.
- A **receita se manteve relativamente estável**, sustentada por um aumento progressivo do preço médio — o que mascara a gravidade da perda de base de clientes.
- O **número de clientes ativos caiu consistentemente**, indicando que o problema não é apenas de volume por cliente, mas de churn real.
- O produto **Lubs1 é o epicentro da queda**, respondendo pela maior parte do volume perdido dado seu peso dominante no portfólio.
- Os mercados de **Energia e Químicos, Ciências e Saúde e Manufatura** concentram as maiores perdas absolutas — e são justamente os mais estratégicos para a empresa.
- A queda **não possui padrão geográfico**: todas as regiões e estados declinaram de forma proporcional, descartando causas locais ou logísticas.
- A faixa de clientes **"Muito Alto"** (acima de 900 L/mês) é responsável pela esmagadora maioria da queda acumulada — tanto em volume quanto em número de clientes perdidos.
- O **Pareto confirmou** que um pequeno grupo de combinações Região + Mercado + Faixa concentra a maior parte da perda, permitindo priorização cirúrgica de ações.

Respostas às Perguntas de Negócio

Pergunta	Resposta
O volume de vendas está caindo?	Sim — queda contínua de 2018 a 2024, sem sinais de reversão
A queda impacta a receita?	Ainda não diretamente — o aumento de preço compensa, mas é insustentável
Quais produtos são os mais afetados?	O Lubs1 é o principal responsável pela queda
A queda está concentrada em algum mercado?	Sim — Energia e Químicos, Ciências e Saúde e Manufatura
Há padrão geográfico na queda?	Não — a queda é homogênea entre regiões e estados
Quais perfis de clientes estão sendo mais perdidos?	Clientes da faixa "Muito Alto" , de forma massivamente desproporcional
A empresa perde clientes ou volume por cliente?	Ambos — churn e redução de consumo ocorrem simultaneamente na faixa crítica
Existem outliers distorcendo a análise?	Sim — 1.051 registros acima da capacidade logística máxima foram removidos, porém, os gráficos não foram afetados significativamente
Quais segmentos concentram a maior parte da queda?	Os primeiros segmentos do Pareto (Sudeste + Energia e Químicos + Muito Alto, entre outros) explicam ~80% da perda

Sugestão de Ações Futuras

- Retenção dos clientes "Muito Alto"** Investigar individualmente os clientes dessa faixa que reduziram volume ou saíram. Entrevistas qualitativas podem revelar se o problema é preço, qualidade, concorrência ou atendimento.
- Revisão da estratégia de precificação** O aumento contínuo de preço pode estar acelerando a saída dos maiores clientes, que têm mais poder de negociação e mais alternativas no mercado. Uma análise de elasticidade-preço por faixa de cliente é recomendada.
- Foco comercial nos mercados críticos** Concentrar esforços de retenção e prospecção nos segmentos de **Energia e Químicos, Ciências e Saúde e Manufatura**, onde a perda absoluta é maior e o potencial de recuperação é mais significativo.
- Plano de ação orientado pelo Pareto** Utilizar os Top 15 segmentos identificados na análise de Pareto como lista de prioridades para o time comercial, com metas específicas de recuperação de volume por segmento.
- Monitoramento contínuo com dashboards** Implementar acompanhamento mensal das métricas-chave (volume, clientes ativos, churn por faixa) para detectar sinais de deterioração com antecedência e agir de forma proativa.

Conclusão

A BF LUBS enfrenta um problema estrutural de perda de clientes de alto valor. A queda de volume não é pontual ou sazonal — é uma tendência de longo prazo que impacta de forma transversal regiões, estados e mercados. A prioridade estratégica deve ser a **retenção e recuperação dos clientes de faixa "Muito Alto"**, com foco especial nos segmentos identificados na análise de Pareto.